

具身智能大模型（智能大脑）的世界模型

研究时间：截至2026年8月18日 · 所属领域：具身智能 / 机器人学习 / 世界模型 · 研究对象类型：技术范式

作者：季玲宇

目录

一、一句话定义与研究边界3

1.1 “智能大脑”不是一颗模型，而是一条闭环3

1.2 本报告的结论先放在桌面上3

二、纵向分析：从「脑内小剧场」到可执行世界-动作模型4

2.1 1943-1995：智能的起点，是先在内脑试一次4

2.2 1990-2014：Dyna 把真实经验和想象经验放进同一循环4

2.3 2015-2017：从像素学习可控潜空间4

2.4 2018-2023：在梦里训练策略，现代世界模型范式成形5

2.5 2022-2025：VLA 先绕过世界模型，把“会做”放在“会想”前面5

2.6 2022-2026：JEPA 选择预测抽象表征，而不是绘制所有像素5

2.7 2023-2026：互联网视频进入物理智能，世界模型变成基础模型6

2.8 纵轴结论：七十多年后，行业回到 Craik 的原始问题6

三、横向分析：2026年的路线与玩家7

3.1 一张表先把生态位分开7

3.2 NVIDIA Cosmos：不是单点模型，而是 Physical AI 的操作系统企图7

3.3 Google：把生成世界与控制机器人分成两条产品线8

3.4 Meta V-JEPA：不必画出未来，也可以用未来规划8

3.5 1X：最明确地把“想象未来”翻译成动作8

3.6 π 、Helix、Skild：它们已经是强行动脑，却不必然是显式世界模型8

3.7 World Labs Marble：空间智能是世界模型的上游，不是动力学的终点9

3.8 中国与 2026 新兴 WAM：从“视频底座后训练”转向原生世界-动作联合9

3.9 “看视频”与“能控制机器”的硬分界9

3.10 benchmark 仍是一片群岛9

四、横纵交汇：世界模型会不会成为机器人的智能大脑10

4.1 历史如何塑造今天的路线位置10

4.2 真正的竞争不是模型参数，而是四个闭环10

4.3 “大脑/小脑”二分正在变得不够用11

4.4 世界模型的近期价值，为什么先在训练侧爆发11

4.5 三个未来剧本11

最可能剧本：分层融合成为主流 11

最危险剧本：视频幻觉被当作物理知识，行业在 demo 中过拟合 11

最乐观剧本：世界-动作联合模型形成“物理预训练”规模规律 11

4.6 我的判断 12

五、结论与决策清单 12

5.1 给技术团队的评估框架 12

5.2 给投资与产业决策者的识别信号 12

5.3 最终结论 13

六、信息来源与方法论说明 13

6.1 思想前史与经典 model-based learning 13

6.2 VLA、JEPA 与机器人基础模型 13

6.3 视频、空间与世界-动作模型 14

6.4 综述、定义与反方证据 15

6.5 方法论说明 15

一、一句话定义与研究边界

一句话定义：具身智能的世界模型，是机器人在行动前用于“预演后果”的内部模拟器；它根据当前观测、历史和候选动作，预测未来状态，并把预测交给规划、策略学习、评估或安全控制。

这个定义故意没有写“生成视频”。一台模型可以像 Sora 那样生成一段极逼真的机械臂视频，却没有机器人动作接口；也可以像 MuZero 那样不画出任何画面，只预测奖励、价值和策略所需的潜在量。前者会画世界，未必能控制世界；后者不画世界，却可以用模型规划。

围绕“机器人的智能大脑”，今天至少有四类常被混用的对象：

名称	核心映射	典型用途	是否等于完整机器人大脑
视频/空间生成模型	文本或图像 → 未来视频、3D 场景	内容生成、场景资产、合成数据	否，通常缺少精确动作条件和真机闭环
行动条件世界模型	观测 + 候选动作 → 未来状态/视频/价值	规划、策略评估、失败预演	接近“预测脑”，但还需策略和控制
VLA 具身策略	视觉 + 语言 + 本体状态 → 动作	直接控制机器人	是“行动脑”，但未必能显式比较多种未来
世界-动作模型	观测、语言、世界状态与动作联合预测	同时想象后果、生成动作、闭环纠错	最接近完整智能大脑，仍处早期验证阶段

本报告用一个更严格的门槛判断“世界模型”是否真的服务于具身智能：它必须对**行动干预**敏感。改变候选动作，预测结果也应相应改变；预测还要在机器人会访问的状态-动作分布上足够准确，能够改善现实任务的决策。只通过文本提示改变镜头、只生成“看起来像成功”的视频，不满足这个门槛。

1.1 “智能大脑”不是一颗模型，而是一条闭环

一台可靠的机器人至少要完成以下循环：

感知当前世界 → 形成任务相关状态 → 生成候选行动 → 预演后果与风险 → 选择并执行 → 重新观测 → 发现偏差后重规划

世界模型位于“预演后果”这一环，但它会反向塑造感知和策略。它决定什么信息值得记住：杯子的花纹可能不重要，杯口姿态、液体高度、抓握点和摩擦却很重要。它也决定机器人能否从失败中产生新经验，而不是每次都在昂贵、危险的真机上试错。

因此，世界模型不是把物理世界复制进 GPU。它是一种有目的的压缩。好模型不必预测每一片树叶怎么晃，但必须知道机械臂向左推时杯子不会向右瞬移；不必重建所有像素，却必须保留会影响行动结果的变量。

1.2 本报告的结论先放在桌面上

截至 2026 年 8 月，世界模型已经从“研究玩具”进入具身智能主赛道，但尚没有任何公开证据证明某个系统实现了跨家庭、跨本体、小时级、无需人工恢复的通用物理智能。

当前最稳健的现实价值排序是：**合成数据与策略筛选** > **表征预训练** > **低频规划和目标生成** > **直接高频控制**。真正值得下注的不是“更大的视频模型”本身，而是三种能力的耦合：互联网视频带来的广泛物理先验、机器人交互带来的行动接地、真机反馈带来的持续纠错。

换一种更直白的说法：下一代机器人**大脑**大概率既不是纯 VLA，也不是一台把未来画得很漂亮的视频生成器，而是“会做、会想、会发现自己想错了”的分层系统。

二、纵向分析：从「脑内小剧场」到可执行世界-动作模型

世界模型的历史并不是分辨率从 64×64 一路涨到 720p。真正的主线，是研究者三次改写了“什么值得预测”：先复原显式状态转移，再只预测决策所需的潜在信息，最后尝试从海量视频获得开放世界物理先验。

2.1 1943-1995：智能的起点，是先在内脑试一次

1943 年，苏格兰心理学家 Kenneth Craik 在《The Nature of Explanation》中提出一个后来反复回响的想法：生物体在头脑中携带外部现实及自身可能行动的“小尺度模型”，因而可以在行动前尝试不同选择。这个直觉已经包含现代世界模型的三个部件：内部表征、后果预测、行动选择。

1948 年，Edward Tolman 用老鼠迷宫实验讨论“认知地图”。动物似乎没有只背下一步怎么走，而是形成了可复用的空间结构；当熟悉路径被堵住，它仍能寻找替代路线。今天 VLA 与世界模型的争论，可以在这里找到原型：稳定环境里，刺激到动作的映射可能足够；目标变化、路径受阻、任务需要组合时，结构化内部表征开始显出价值。

到了 1990 年代，forward model 和 inverse model 进入运动控制。forward model 根据当前状态和运动命令预测后果；inverse model 根据期望变化反推动作。七十多年后，1XWM 又把这对概念接了回来：先生成机器人完成任务的未来视频，再通过 inverse dynamics model 还原可执行动作。

这个阶段解决了“为什么需要模型”，没有解决“模型如何从相机、触觉和关节数据中自己学出来”。

2.2 1990-2014：Dyna 把真实经验和想象经验放进同一循环

Richard Sutton 在 1990 年提出 Dyna 类架构，1991 年进一步概括为学习、规划和反应的一体化系统。Dyna 的关键不是单独训练一个预测器，而是让同一价值函数吸收两类经验：一类来自真实交互，另一类由已学模型生成。

这套循环至今没有过时：

真实交互 → 更新世界模型 → 在模型中生成经验或规划 → 更新策略 → 再回到真实世界

传统规划依赖给定且准确的模型；纯 model-free 强化学习不需要模型，却把每条真实经验只用一次。Dyna 接受模型可能不完整，用想象把稀缺经验反复利用。它也留下了世界模型最顽固的三个问题：分布外预测会错，长滚动会累积误差，策略会主动钻模型漏洞。

Dyna 还埋下一条重要的术语边界。世界模型的价值不是“生成一段真实感内容”，而是能被行动选择系统查询。对具身智能而言，能否回答“如果我做 A 和做 B，分别会怎样”，比单一路径的视觉质量更重要。

2.3 2015-2017：从像素学习可控潜空间

摄像头把经典控制问题突然变得很大。状态不再是几个干净变量，而是一张包含光照、纹理、遮挡和无关背景的图像。

2015 年的 Embed to Control 用 VAE 把图像压入潜空间，并约束潜在动力学局部线性，让传统最优控制可以在这个空间工作。它传递出一个反直觉信号：预测画面更准的模型，不一定控制更好。潜空间应由“能否用于控制”塑造，而不是只由重建像素塑造。

2016 年，Chelsea Finn、Ian Goodfellow 与 Sergey Levine 从约 5.9 万次机器人推动交互学习行动条件视频预测。随后 Deep Visual Foresight 把预测器接到 model predictive control：采样多组动作，生成各自未来画面，选出最可能把目标像素移动到指定位置的动作，只执行第一步，再重新规划。

这已经很像今天的机器人视频世界模型。可当时的像素回归会把多种可能未来平均成模糊画面，长期滚动快速漂移；相机和机械臂形态固定，任务多为短视距推物。研究者很快意识到，像素无需人工标注，却也包含太多不可预测、与决策无关的细节。

2.4 2018-2023：在梦里训练策略，现代世界模型范式成形

2018 年，David Ha 与 Jürgen Schmidhuber 的《World Models》让“在模型生成的梦里训练策略”成为可复现实验。VAE 压缩画面，MDN-RNN 学习潜状态随动作的随机演化，小型 controller 在潜状态上行动。策略甚至可以完全在梦境中训练，再迁移回游戏环境。

这篇工作把概念带出了小圈子，也暴露出危险：如果梦境不准，策略并不会善意忽略错误，它会系统性利用模型漏洞。对机器人而言，这类 model exploitation 可能不是游戏里的高分技巧，而是穿过桌面、忽略碰撞或把抓空预测成成功。

2019 年的 PlaNet 用 Recurrent State Space Model 把确定性记忆和随机潜变量结合起来，并通过多步约束改善长期一致性。它不必解码每一个候选未来，只在潜空间预测奖励，再用在线规划选动作。世界模型第一次比较完整地把高维视觉、部分可观测性、不确定性和控制放进同一架构。

同年公开、2020 年发表于 ICLR 的 Dreamer 又做了一次工程改写。PlaNet 每一步都要搜索；Dreamer 让 actor 和 critic 在潜空间想象轨迹中学习，把大量规划计算“编译”进策略。部署时 actor 可以直接输出动作。规划没有消失，只是不再以显式搜索的形态出现在每次推理中。

DreamerV2 用离散潜变量在 Atari 上跨过人类水平；DreamerV3 用稳定化技巧在 150 多个任务上保持同一组超参数，并从像素和稀疏奖励出发在 Minecraft 获得钻石。2025 年《Nature》版本证明这条路线可以跨很多任务稳定工作。但这些任务主要仍是游戏和仿真，并不自动等价于开放家庭里的物理常识。

MuZero 则给生成式路线泼了一盆很有价值的冷水。它不重建像素，也不追求可解释的完整物理状态，只递归预测树搜索需要的奖励、策略和价值。结果是在不知道游戏规则的情况下匹配或超过强规划系统。MuZero 提醒行业：如果目标是决策，“完整生成世界”可能是一笔昂贵的浪费；但任务相关压缩也会丢掉当前奖励没覆盖、换任务后却很关键的因素。

2022 年的 DayDreamer 把潜世界模型真正带到实体机器人：四足机器人从零学习翻身、站立和行走，机械臂学习抓放，轮式机器人学习导航。它证明 Dreamer 类方法并非只能活在模拟器中，也暴露出真机在线强化学习的代价：任务仍窄、奖励需定义、探索会带来碰撞、磨损和复位成本。

2.5 2022-2025：VLA 先绕过世界模型，把“会做”放在“会想”前面

RT-1、PaLM-E、RT-2、Open X-Embodiment、Octo、 $\pi 0$ 和 GR00T 共同推进了另一条主线：不显式预测未来，直接学习“视觉、语言和本体状态到动作”的映射。

这条路线崛起不是偶然。行为克隆训练稳定，部署只需一次前向推理，不会在长滚动中反复累积生成误差；VLM 已从互联网获得物体和语义知识，短程操作中直接动作映射经常已经够用。RT-2 把动作编码成 token，正式提出 Vision-Language-Action； $\pi 0$ 用 flow matching action expert 生成连续动作；GR00T 以慢速 VLM 理解和快速动作生成形成双系统。

VLA 的代价是把“想象”藏了起来。模型可以做出动作，却未必能外显回答：如果换一个动作会怎样，当前计划为什么会失败，哪一种候选路径风险更低。短任务里这不总是问题；一旦进入长程家务、安全验证、自我训练和策略评估，预测层又会回来。

因此，VLA 不是世界模型的失败证据。它更像工程团队为避开模型误差而走出的旁路。

2.6 2022-2026：JEPA 选择预测抽象表征，而不是绘制所有像素

Yann LeCun 在 2022 年的自主机器智能架构中提出层级世界模型、actor、critic、短期记忆和内在代价。其核心判断是：现实未来具有多模态和大量不可预测细节。树叶具体怎样抖动不重要，杯子失去支撑后会下落才重要。

I-JEPA 在静态图像中预测被遮挡区域的表征；V-JEPA 把原则扩展到视频。它们不生成像素，而是在 embedding space 预测抽象状态，主动舍弃难以预测的细节。严格说，早期 I-JEPA 和 V-JEPA 是强表征学习器，不是行动条件动力学模型。

2025 年的 V-JEPA 2-AC 才补上具身所需的那一步。模型先用超过 100 万小时互联网视频做无动作预训练，再用不足 62 小时 DROID 机器人视频训练行动条件 predictor，最后在两个实验室的 Franka 机器人上用目标图像和 MPC 做零样本抓取、到达与放置。它是“广泛观察预训练 + 少量动作接地 + 闭环规划”目前最干净的公开证据之一。

边界也很清楚：任务仍以短程操作为主，长任务需要人工给视觉子目标，单一 embedding 距离未必能表示所有任务进度。它证明 latent world model 可以控制机器人，还没有证明一台模型能自己完成十分钟家务。

2.7 2023-2026：互联网视频进入物理智能，世界模型变成基础模型

机器人数据昂贵、硬件异构、失败样本难采。于是研究目标发生了第三次迁移：先从互联网视频学习“世界通常怎样变化”，再用少量人类第一视角与机器人传感运动数据进行接地。

UniSim 把图像、导航、机器人和仿真数据编排在一起，既响应高层语言，也响应低层动作，并让在生成环境中训练的策略迁移到现实。Genie 从无动作标签视频学习潜动作，生成可以逐帧交互的世界；Sora 展示视频生成的规模效应，同时官方也明确列出物体凭空出现、交互物理错误和长时不一致。二者共同点是打开了“视频模型能否成为世界模拟器”的想象，差别是 Genie 追求交互，Sora 的初始公开形态没有机器人动作接口。

NVIDIA Cosmos 在 2025 年把世界模型从单个模型扩成 Physical AI 平台：数据整理、视频 tokenizer、预测与推理模型、合成数据、后训练和部署被连成供应链。DreamGen 用视频模型生成新任务轨迹，再通过 latent action model 或 inverse dynamics 恢复伪动作，训练下游机器人策略。2026 年 Cosmos 3 又把语言、图像、视频、声音和动作放进统一 omnimodal 架构。

1XWM 则把路线推得更直接。2025 年版本主要评估 humanoid policy：给定观测和低层动作轨迹，预测未来并判断策略价值。2026 年版本让 14B 视频底座先经过 900 小时第一视角人类视频和 70 小时 NEO 数据接地，再从文本和初始帧生成目标未来，IDM 把画面转成动作。互联网视频提供长尾对象和动作知识，机器人数据负责让“看起来会做”变成“这台身体做得到”。

世界模型与 VLA 也在网络内部汇合。FLARE 给动作策略增加未来 latent alignment 目标，让模型在输出动作同时预测未来表征；GR00T N1.5 使用类似辅助目标改善策略与人类视频迁移。WorldVLA、Cosmos 3、Kairos 等 2025-2026 年工作进一步联合预测未来世界和机器人动作。术语开始从 world model 移向 World-Action Model。

2.8 纵轴结论：七十多年后，行业回到 Craik 的原始问题

纵轴上最重要的变化可以压缩成三句话：

1. 世界模型从显式低维动力学，转向任务相关潜状态，再转向利用视频基础模型吸收开放世界先验。
2. VLA 因部署效率和训练稳定性先取得工程优势，世界模型则在长程规划、反事实评估、数据生成和安全验证中重新获得位置。
3. 未来较可能是显式与隐式预测共存：低频层展开候选未来，高频层用轻量策略快速反应，执行后持续用真实观测纠偏。

历史最后绕回 1943 年的直觉。智能的关键不是把现实复制得足够漂亮，而是在真正行动前，能够用一个足够有用的内部模型先活过几种未来。

三、横向分析：2026年的路线与玩家

2026 年的横向竞争看上去很热闹，真正的直接竞品却没有想象中多。Genie 3、Marble、Cosmos、V-JEPA、1XWM、 π 0.5、Helix 都被放进“世界模型/物理智能”的同一张海报，但它们优化的目标并不相同。

3.1 一张表先把生态位分开

下表的“真机闭环”只承认模型或其策略接收真实观测、输出动作、执行后再次观测的循环。公司演示、离线生成和在虚拟世界里导航不自动算真机闭环。

路线/玩家	核心输出与行动接口	真机闭环证据	开放性	当下最强生态位	主要证据边界
NVIDIA Cosmos 3	文本、图像、视频、声音、动作可联合输入输出；含 policy 形态	有策略 benchmark 与合作部署，通用长期真机证据仍有限	权重、代码与部分训练/评测流程开放	Physical AI 基础设施平台	大量结果来自厂商测试，跨本体与长程接触需独立验证
Google Genie 3	文本生成 720p、约 24 fps 可交互世界；有限动作空间	SIMA 可在生成世界交互；未证明直接控真机	闭源研究/产品体验	无限课程与交互环境生成	官方承认多智能体、数小时一致性和动作空间仍有限
Google Gemini Robotics	高层 ER 规划 + VLA 直接输出机器人动作	强，多本体、长任务与闭环纠错	ER 部分 API；VLA 面向伙伴，权重未开	闭源通用机器人大脑	不是公开可查询的生成式世界模型，评测多为自有任务
Meta V-JEPA 2-AC	观测 + 候选动作 → 未来潜在状态，用 MPC 规划	有，Franka 到达、抓取、放置	代码和权重公开	高效潜空间预测与开放研究	任务窄、长任务需人工视觉子目标
1XWM	文本 + 初帧 → 未来视频 → IDM 动作；早期版也支持低层动作条件预测	有，集成 NEO	垂直闭源	视频想象到真机动作的完整样板	深度、几何、接触仍会错；benchmark 主要来自自评
Physical Intelligence π 系列	视觉/语言/本体状态 → 连续动作块	强，多机器人与现实长任务	openpi 部分开放	直接策略和跨场景泛化	强 VLA 对照组，不一定提供显式反事实 rollout
Figure Helix	多相机、触觉、本体状态 → 高频全身动作	强，软硬件一体	闭源	全身、高频、商业场景执行	公开演示多，统一 benchmark 和独立复现少
World Labs Marble	多模态输入 → 可编辑、可导出 3D 世界	无公开机器人闭环	产品/API，模型闭源	空间场景、数字孪生、仿真资产	静态或可编辑 3D 不等于接触动力学和动作控制
Kairos 等新兴 WAM	世界状态、视频与动作联合预测	有开源 benchmark 与动作预测主张	代码/4B 权重开放	世界-动作联合与边缘部署探索	2026 新成果，结果以团队自报为主，产业验证时间短

这张表揭示了一个很容易被忽略的事实：**会生成世界、会预测世界、会控制机器人，是三种不同能力**。理想系统会把三者接起来，但今天大部分玩家只在其中一两项上拥有强证据。

3.2 NVIDIA Cosmos：不是单点模型，而是 Physical AI 的操作系统企图

Cosmos 的优势不在某一段机器人视频，而在于把数据处理、视频 tokenization、世界生成、物理推理、合成数据、策略训练、Isaac 仿真和 NVIDIA 算力放进同一套供应链。

2025 年首发的 Cosmos 更接近通用物理视频基础模型：开发者以文本、图像、视频、轨迹等条件生成未来视频，再为机器人或自动驾驶做领域后训练。到 2026 年 Cosmos 3，语言、图像、视频、声音和动作进入统一架构，模型可以朝理解器、forward dynamics、inverse dynamics 或 robot policy 方向定制。它从“生成数据的上游”向“智

能大脑底座”移动了一层。

Cosmos 的商业护城河也最清楚。机器人公司不必自己从零训练世界基础模型，可以在 NVIDIA 的 GPU、Isaac、Omniverse、GR00T 和 Cosmos 上完成数据到部署。开放权重又降低了硬件厂商押注闭源 API 的顾虑。

但 “physics-aware” 不是物理引擎的同义词。开放 benchmark 和合成数据价值已经可验证，复杂接触、柔性物体、跨硬件零样本迁移、分钟级现实任务稳定性仍缺同条件第三方检验。Cosmos 当前更像行业公路，不是已经抵达终点的自动驾驶员。

3.3 Google：把生成世界与控制机器人分成两条产品线

Google 没有强行让一台模型包打天下。

Genie 3 面向实时可交互世界。它从文本生成 720p 环境，以约 24 fps 响应导航动作，保持几分钟一致性，还能触发文本描述的 world events。SIMA 可以在生成世界里行动，因此 Genie 很适合构造无限训练课程、评估 agent、制造少见场景。

Gemini Robotics 则面向真机。高层 embodied reasoning 模型负责工具调用、任务拆解、进度判断和语义安全，VLA 负责把步骤变成具体动作，底层控制器处理碰撞、平衡和高频执行。这是一种务实的“慢思考 + 快行动”架构。

两条线在公司愿景里互补，公开证据却没有表明 Genie 已成为 Gemini Robotics 的内部 MPC 模拟器。因此不能把 Genie 的几分钟视觉一致性，直接算成 Gemini Robotics 的几分钟现实控制能力。Google 的优势是完整闭源栈和强多模态语义；弱点是研究者很难检查其动作接地、训练数据与统一评测。

3.4 Meta V-JEPA：不必画出未来，也可以用未来规划

V-JEPA 选择一条与视频生成几乎相反的路线。它不承担每个像素的重建，而是在潜在空间预测任务相关状态。纹理、阴影和随机背景不再消耗同等容量，候选动作也能更快地滚动比较。

V-JEPA 2-AC 最有说服力的不是视频理解榜单，而是数据结构：超过 100 万小时无动作视频负责广泛观察，不足 62 小时 DROID 数据负责把动作接入模型，随后用 MPC 在两个未参与训练的实验室环境中控制 Franka。它提供了少见的开放、可检验路线。

它也因此显得“窄而真”。当前公开控制集中在 reaching、grasping、pick-and-place；长任务需要人工提供视觉子目标；模型还没有独立完成开放家庭任务的证据。Meta 证明了潜模型可以成为预测脑，没有证明预测脑已经可以独立承担整颗大脑。

3.5 1X：最明确地把“想象未来”翻译成动作

1X 的路线变化很有代表性。2025 年版本让世界模型接收机器人观测和候选低层动作，预测未来并辅助 policy evaluation；2026 年版本则先根据文本想象 NEO 应该如何完成任务，再由 IDM 从相邻生成帧中还原动作。

这套方案把互联网视频的可扩展性发挥得很直接：14B 视频底座先吸收广泛运动先验，900 小时第一视角人类视频对齐操控视角，70 小时 NEO 数据对齐具体身体；IDM 另用约 400 小时机器人数据学习动作恢复。相比从零收集每个任务的遥操作示范，它提供了一条更经济的数据路径。

1X 自己披露的失败样例同样重要。生成可能过度乐观：视频里物体已经放好，现实机器人却因单目深度误差抓空；对象会在接触中改变形状或关系；训练分布中的共同运动会让模型误判物体能否分离。好看的目标视频只有在视觉、运动学、动力学三层都接地时，才是可执行计划。

3.6 π 、Helix、Skild：它们已经是强行动脑，却不必然是显式世界模型

Physical Intelligence 的 π 系列、Figure Helix 与 Skild Brain 代表直接策略路线的三种取向。

π 系列强调跨机器人数据、VLM 知识迁移、连续动作生成和现实强化学习；Helix 强调软硬件共设计，以语义层、200Hz 视觉运动层和 1kHz 稳定控制层完成全身、双手与触觉闭环；Skild 强调大规模仿真和跨本体控制先验。

这些系统可能在内部隐式编码大量世界规律，现实执行证据甚至比不少显式世界模型更强。但严格来说，若系统没有公开“给定候选动作，输出可检查未来”的接口，就不能因为它很聪明而自动归入行动条件世界模型。

这个区别不只是学术洁癖。显式或可查询的预测器可以用于反事实评估、失败筛查、策略排名和安全审计；直接策略则以更低延迟直接优化真机成功率。工程上最可能的结果是合流：策略用未来表征作为辅助目标，世界模型在低频层做候选 rollout，低层控制继续由快速策略承担。

3.7 World Labs Marble：空间智能是世界模型的上游，不是动力学的终点

Marble 能从文本、图片、视频和粗 3D 布局生成可编辑三维世界，并导出 Gaussian splats、mesh 或视频。它解决了纯逐帧视频常见的视角变化、结构漂移和显式几何缺失，适合作为场景重建、数字孪生、仿真资产和空间记忆层。

公开资料没有证明 Marble 能按机械臂关节轨迹精确模拟摩擦、碰撞、柔性物体与接触结果，也没有真机闭环 benchmark。把它纳入世界模型图谱是必要的，把它与 V-JEPA 2-AC 或 1XWM 做控制排名则会制造假比较。

3.8 中国与 2026 新兴 WAM：从“视频底座后训练”转向原生世界-动作联合

2026 年中国团队集中出现 Qwen-RobotWorld、WorldVLA、RepWAM、Kairos、Motubrain 等方案。它们的共同语言是：不再把视频生成与动作预测当作两个完全分离的后处理模块，而让世界状态、语言和动作 token 在同一 backbone 中交互，或以未来世界预测约束动作生成。

Kairos 公开 4B 权重与动作预测版本，主张通过跨本体数据课程、持久状态和线性时间记忆兼顾长程与边缘部署；Qwen-RobotWorld 用语言条件视频统一多种 embodiment 的动作语义；WorldVLA 联合未来图像 token 与动作 token。它们说明 WAM 已从论文概念变成密集工程赛道。

这些结果仍要放在正确证据层级。2026 年的新 benchmark、公司榜单和 SOTA 大多由发布团队自报，训练数据、真实机器人条件与成功定义不统一；开放权重是可复现的起点，不是产业可靠性的终点。

3.9 “看视频”与“能控制机器”的硬分界

问题	视频生成/交互环境模型	控制用世界模型
条件	文本、初始画面、粗导航事件	精确动作、关节状态、末端位姿、触觉、本体感觉
优化目标	未来看起来合理	候选动作后的任务相关状态必须正确
身体约束	可以近似或忽略	必须满足关节限位、速度、力矩、平衡和时延
物理误差	轻微穿模可能不影响观感	毫米误差、摩擦和接触顺序都可能导致失败
不确定性	生成一条 plausible future 常已够用	要覆盖多种未来、校准风险、识别 OOD
长时性	身份和场景不漂移	还要保持任务进度、资源、逻辑与安全约束
评测	FVD、美学、人类偏好、物理问答	动作服从、策略排序、真机成功、失败恢复

从“看”到“做”至少要跨三层接地：相机和深度构成的视觉/空间接地，关节与可达域构成的运动学接地，力、摩擦、柔性体和控制延迟构成的动力学接地。再往前还要补上价值与安全：它不仅要预测会发生什么，还要判断是否完成、风险多大、失败后怎样恢复。

3.10 benchmark 仍是一片群岛

当前不存在一个同时覆盖生成质量、物理因果、行动服从、闭环控制、跨本体和长时真实任务的统一榜单。

视频理解类 benchmark 测动作识别和未来预期，不能证明能控机器人；直觉物理 benchmark 能抓出违反守恒或对对象恒常性的画面，不能证明动作精度；LIBERO、RoboTwin 等策略 benchmark 更接近控制，却仍受仿真、数据划分和具体本体影响；公司真机任务最接近现实，但任务选择与成功定义难以横比。

Physics-IQ、WorldModelBench、RoboWM-Bench 与 MiraBench 等新评测传递了相似警告：视觉真实感与物理正确性相关性很弱；模型会忽略动作条件，生成一条流畅但错误的未来；还会出现 optimism bias，在失败动作下想象成功结果。

因此，现阶段世界模型最稳妥的部署方式不是取代真机验证，而是减少真机测试量、筛掉明显差策略、生成训练数据、提供低频候选未来。最终上线仍需真实传感器、约束控制、安全盾与持续回归测试。

四、横纵交汇：世界模型会不会成为机器人的智能大脑

把时间轴和 2026 年竞争图谱叠在一起，一个判断会变得很清楚：世界模型不会以“单独一颗万能视频模型”的形态取代 VLA，而会成为机器人智能栈里的预测中枢，并逐步与策略共享表征、数据和训练目标。

4.1 历史如何塑造今天的路线位置

Dreamer、MuZero 和 TD-MPC2 继承了 Dyna 的任务导向传统。它们愿意牺牲画面可解释性，换取低成本滚动和决策相关性。今天 V-JEPA 2-AC 在横向比较中显得高效、开放、任务却较窄，正是这段历史的结果：它选择“足够做决定的抽象未来”，没有承担生成一整段世界的成本。

Genie、Cosmos、1XWM 和 Marble 则从视觉生成与空间建模成长起来。它们的优势是可以吸收互联网规模数据、生成可视化未来、制造训练场景；短板是视频目标天然偏向视觉似真，动作忠实与接触物理要靠后训练补上。

1XWM 的 IDM、Cosmos 的动作统一、World Labs 对显式 3D 的坚持，都是在偿还这一历史债务。

π 、Helix 和 Gemini Robotics 的直接策略路线来自另一个现实约束：真机需要低延迟，工程团队不能等待一个完美模拟器。它们先用行为克隆、VLM 迁移和层级控制解决“怎么做”。今天再加入 future latent prediction、进度估计、失败检测或高层规划，是把“会想”补回一套已经会行动的系统。

早期的好决策也可能成为今天的包袱。潜世界模型压缩得过于任务相关，换任务会丢信息；视频模型追求视觉质量，推理延迟和物理幻觉会妨碍控制；垂直一体的机器人公司拥有数据闭环，却容易把模型锁死在单一硬件；开放通用平台容易扩生态，又未必掌握最有价值的真机失败数据。

4.2 真正的竞争不是模型参数，而是四个闭环

第一是**数据闭环**。互联网视频提供对象、动作和常识的长尾覆盖，但没有精确关节、力、触觉和失败标签。机器人数据提供行动干预，却昂贵且被具体硬件锁定。领先者会把 web video、人类第一视角、仿真、遥操作、无目的 play data、部署日志和失败恢复串成课程，而不是押注单一数据源。

第二是**模型闭环**。世界预测和动作生成若由两个彼此独立的模型承担，误差会在接口处放大；若完全统一，训练又可能互相干扰。World-Action Model 的价值不在名字，而在同一潜状态必须同时回答两道题：下一步做什么，做了以后世界怎样。两种答案如果冲突，系统应该暴露不确定性，而不是继续生成一条顺滑动作。

第三是**执行闭环**。长期任务不能一次生成完。可靠做法是短滚动、高频重观测、分层时标：低频层拆解任务和比较候选未来，中频策略输出动作块，低层控制器以触觉、本体感觉和安全约束稳定执行。现实偏差不是异常，而是系统设计的常态输入。

第四是**验证闭环**。世界模型必须预测失败，不只生成成功。训练集若以演示为主，模型会形成 optimism bias：不管给什么动作都想象任务被完成。未来高价值数据可能恰恰是摔落、卡住、抓空、滑移、被人打断和传感器异常，因为

这些数据决定模型能否识别危险边界。

4.3 “大脑/小脑”二分正在变得不够用

行业常把 LLM/VLM 叫“大脑”，把运动控制叫“小脑”。这个比喻适合解释语义与动作分工，却遗漏了世界模型扮演的角色。

更合适的三层结构是：语义规划脑回答“我要完成什么”，世界预测脑回答“如果这样做会发生什么”，运动控制脑回答“这一毫秒怎样稳定地做”。三层未必是三个独立神经网络，但三种功能缺一不可。

只靠语义规划，机器人会说合理步骤，却对接触和深度无感；只靠直接策略，机器人可以在熟悉分布上做得很快，却难以外显比较风险；只靠世界模拟，机器人会生成许多未来，却不知道哪一个值得追求，也可能赶不上控制频率。

“智能大脑”的成熟标志不是三层彻底合并，而是它们共享状态、可以互相校验，并在不同时间尺度上协作。

4.4 世界模型的近期价值，为什么先在训练侧爆发

直接把 10B 级视频模型塞进 200Hz 控制回路并不经济。世界模型更早兑现的价值会出现在训练和验证：生成稀有场景，扩充策略数据，给 policy 做离线筛选，在数字孪生中测试长尾，帮助 VLA 学未来表征，或为低频规划提供目标视频。

这里存在一条容易被低估的商业路线：世界模型不必自己成为最终 policy，也可以成为所有 policy 的“考场”和“数据工厂”。NVIDIA 的平台布局、1X 的 policy evaluation、DreamGen 的 neural trajectories 都在这个方向上。谁能证明生成数据提高真机成功、模拟排名保持真实策略相对优劣，谁就拥有比视觉 demo 更坚实的产品价值。

4.5 三个未来剧本

最可能剧本：分层融合成为主流

未来两到三年，VLA 仍承担大部分实时动作，世界模型主要负责预训练、短视界 rollout、目标生成、失败检测和策略评估。大型机器人公司保留垂直数据闭环，NVIDIA 等平台供应通用底座，开放模型围绕不同本体后训练。future latent auxiliary loss 会普遍进入 VLA，显式视频 rollout 只在低频或高风险步骤调用。

这个剧本最符合当前证据：VLA 已有较强真机表现，V-JEPA 2-AC 证明潜在预测可参与 MPC，1XWM 证明视频到动作可工作，Cosmos 展示平台化供给。没有一条路线需要被另一条彻底消灭。

最危险剧本：视频幻觉被当作物理知识，行业在 demo 中过拟合

资本和市场偏爱可视化。一段漂亮的机器人未来视频比一张不确定度校准曲线更容易传播。如果公司用美学、人类偏好和挑选后的成功片段替代行动服从、失败预测和真机统计，世界模型会成为昂贵的数据污染器。合成轨迹把错误接触写进策略，模拟器高估 OOD policy，模型又用自己的乐观未来给自己打分，闭环会越训练越自信。

这一剧本的预警信号包括：只报生成清晰度，不报动作条件消融；只展示成功样例，不公开失败分布；benchmark 全由发布方定义；仿真提升很大，真机无同任务对照；模型没有 OOD 检测和安全 fallback。

最乐观剧本：世界-动作联合模型形成“物理预训练”规模规律

若海量视频确实能提供可迁移的对象、几何和动力学先验，少量行动数据又能稳定校准干预关系，那么机器人可能复制 LLM 的两阶段跃迁：通用世界预训练获得广度，具体本体后训练获得行动精度，部署交互再通过强化学习获得可靠性。

在这个剧本里，同一潜状态能生成未来视频供人检查，输出动作供机器人执行，预测价值供规划排序，还能估计置信区间；跨本体数据通过统一空间、动作或语言接口迁移；真机失败自动进入训练飞轮。机器人不再为每个家庭和工位

从头采集成千上万条示范，而是在少量接地后复用大部分世界知识。

乐观剧本能否发生，取决于四个联合指标而不是参数量：动作服从率、长视界状态一致性、OOD 不确定度校准、真实机器人闭环任务成功率。

4.6 我的判断

世界模型会成为具身智能的关键部件，但“成为智能大脑”这句话只说对了一半。它更像大脑里的预测机制，而不是完整人格。目标、价值、记忆、策略、控制和安全仍要共同工作。

我更看好**潜空间预测 + 可选视频解码 + 世界-动作共享表征 + 分层闭环**，而不是始终在像素空间自回归生成。潜空间承担高频、任务相关的预测，视频解码承担可视化、数据生成和审计；高层模型做反事实比较，低层策略保证实时性。这种组合同时尊重了 Dreamer/MuZero 的历史经验，也利用了视频基础模型带来的规模优势。

真正的拐点不会是下一段机械臂视频更清晰，而是模型在一个没见过的真实厨房里，能对“抓杯柄、托杯底、先挪开旁边盘子”给出校准过的多种后果，选择安全方案；执行后发现杯子比预期更滑，再自行修正。

那一刻，机器才不是在播放学过的动作，而是真的在行动前想了一下。

五、结论与决策清单

5.1 给技术团队的评估框架

评估一个“具身世界模型”项目时，不要先问参数量和生成分辨率。先问以下十个问题：

1. 输入里是否包含精确机器人动作、本体状态和时间戳，而不只是文本提示？
2. 同一初始状态下改变动作，预测后果是否稳定、可区分、符合动作幅度？
3. 预测目标是像素、显式 3D、潜状态、奖励/价值，还是多者联合？它为什么适合目标任务？
4. 是否经过相机、深度、具体本体、关节约束与接触动力学的接地？
5. 在多少步后开始漂移？执行是否采用短滚动与真实观测重规划？
6. 是否建模多种可能未来和置信度，还是只给一条最乐观样本？
7. benchmark 是视频观感、仿真成功、策略排序，还是真机闭环？失败定义和样本数是否公开？
8. 模型是否见过失败、干扰、传感异常和 OOD 动作？
9. 推理延迟、显存、控制频率与部署硬件是否匹配？
10. 世界模型带来的收益，是否在同数据、同策略、同本体的消融中转化为真机成功率或安全提升？

5.2 给投资与产业决策者的识别信号

强信号包括：开放行动条件接口；公开失败样例和不确定度；跨场景真机重复试验；模拟器预测与现实 policy 排名有相关性；合成数据对下游真机有对照增益；数据闭环包含部署失败；模型能在多种本体上以较少数据接地。

弱信号包括：把视频生成时长当作任务执行时长；把“physics-aware”当作物理精确；用单一公司 benchmark 宣布通用 SOTA；只展示挑选后的 demo；宣称从视频直接学会控制，却不披露机器人动作数据；把 VLA 的内部常识直接称为可反事实世界模型。

5.3 最终结论

具身智能世界模型已经跨过“有没有用”的争论，进入“在哪一层最有用、怎样被验证”的阶段。潜模型证明了想象可以提高样本效率和规划能力；视频基础模型提供开放世界的视觉与运动先验；VLA 证明直接策略更容易先落地；2025-2026 年的 WAM 则试图让三者汇合。

今天没有赢家通吃。NVIDIA 占据平台，Google 拥有闭源双线，Meta 提供开放潜模型，1X 把视频想象接进 NEO， π 与 Helix 继续用真机数据强化直接策略，中国新兴团队密集探索世界-动作联合与边缘化。竞争焦点正从“谁能生成”转向“谁能在真实闭环中预测错误、服从动作、保持长期一致，并在看错时知道自己看错了”。

对“世界模型是不是机器人的智能大脑”，最准确的回答是：**它将成为智能大脑不可缺的预测机制，但只有进入感知-想象-行动-反馈-安全的完整闭环，才配得上“大脑”这个名字。**

六、信息来源与方法论说明

以下来源均于 2026 年 8 月 18 日访问。一手论文、官方项目页和开放仓库优先；厂商演示和自报 benchmark 在正文中均按证据边界处理。

6.1 思想前史与经典 model-based learning

1. Kenneth Craik, The Nature of Explanation (1943) : <https://mechanism.ucsd.edu/bill/teaching/models/craik.pdf>
2. Edward Tolman, Cognitive Maps in Rats and Men (1948) : <https://pubmed.ncbi.nlm.nih.gov/18870876/>
3. Sutton, Integrated Architectures for Learning, Planning, and Reacting (1990) : <https://mlanthology.org/icml/1990/sutton1990icml-integrated/>
4. Watter et al., Embed to Control (2015) : <https://arxiv.org/abs/1506.07365>
5. Finn et al., Unsupervised Learning for Physical Interaction through Video Prediction (2016) : <https://arxiv.org/abs/1605.07157>
6. Finn & Levine, Deep Visual Foresight for Planning Robot Motion (2016) : <https://arxiv.org/abs/1610.00696>
7. Ha & Schmidhuber, World Models (2018) : <https://arxiv.org/abs/1803.10122>
8. Hafner et al., PlaNet (ICML 2019) : <https://proceedings.mlr.press/v97/hafner19a.html>
9. Hafner et al., Dream to Control (ICLR 2020) : <https://arxiv.org/abs/1912.01603>
10. Hafner et al., DreamerV3 (Nature 2025) : <https://www.nature.com/articles/s41586-025-08744-2>
11. Schrittwieser et al., MuZero (Nature 2020) : <https://www.nature.com/articles/s41586-020-03051-4>
12. Wu et al., DayDreamer: <https://arxiv.org/abs/2206.14176>
13. Hansen et al., TD-MPC2 (ICLR 2024) : https://proceedings.iclr.cc/paper_files/paper/2024/hash/cf73d57b6dcda32b293df7c2d5341f49-Abstract-Conference.html

6.2 VLA、JEPa 与机器人基础模型

14. RT-1: <https://arxiv.org/abs/2212.06817>
15. RT-2: <https://arxiv.org/abs/2307.15818>

16. Open X-Embodiment: <https://arxiv.org/abs/2310.08864>
17. Octo: <https://arxiv.org/abs/2405.12213>
18. Physical Intelligence $\pi 0.5$: <https://www.pi.website/blog/pi05>
19. Figure Helix: <https://www.figure.ai/news/helix>
20. NVIDIA GR00T N1.5: https://research.nvidia.com/labs/gear/gr00t-n1_5/
21. LeCun, A Path Towards Autonomous Machine Intelligence (2022) : <https://openreview.net/pdf?id=BZ5a1r-kVsf>
22. Meta V-JEPA: <https://ai.meta.com/blog/v-jepa-yann-lecun-ai-model-video-joint-embedding-predictive-architecture/>
23. Meta V-JEPA 2 与 V-JEPA 2-AC: <https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>
24. V-JEPA 2 论文页: <https://ai.meta.com/research/publications/v-jepa-2-self-supervised-video-models-enabling-understanding-prediction-and-planning/>
25. FLARE: <https://arxiv.org/abs/2505.15659>

6.3 视频、空间与世界-动作模型

26. UniSim: <https://arxiv.org/abs/2310.06114>
27. Google DeepMind Genie 1: <https://arxiv.org/abs/2402.15391>
28. Google DeepMind Genie 3: <https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>
29. OpenAI, Video generation models as world simulators: <https://openai.com/index/video-generation-models-as-world-simulators/>
30. NVIDIA Cosmos 首发论文: https://research.nvidia.com/publication/2025-01_cosmos-world-foundation-model-platform-physical-ai
31. NVIDIA Cosmos 3 技术报告: <https://research.nvidia.com/labs/cosmos-lab/cosmos3/technical-report.pdf>
32. NVIDIA DreamGen: <https://arxiv.org/abs/2505.12705>
33. 1X World Model (2025) : <https://www.1x.tech/discover/redwood-ai-world-model>
34. 1XWM 从视频到动作 (2026) : <https://www.1x.tech/discover/world-model-self-learning>
35. World Labs Marble: <https://www.worldlabs.ai/blog/marble-world-model>
36. GR-2: <https://arxiv.org/abs/2410.06158>
37. WorldVLA: <https://arxiv.org/abs/2506.21539>
38. Qwen-RobotWorld: <https://arxiv.org/abs/2606.17030>
39. Kairos 开放仓库: <https://github.com/kairos-agi/kairos>

6.4 综述、定义与反方证据

- 40. World Model for Robot Learning: A Comprehensive Survey (2026) : <https://arxiv.org/abs/2605.00080>
- 41. A Comprehensive Survey on World Models for Embodied AI (2025) :
<https://arxiv.org/abs/2510.16732>
- 42. A Definition and Roadmap for World Models (2026) : <https://arxiv.org/abs/2607.06401>
- 43. Physics-IQ: <https://arxiv.org/abs/2501.09038>
- 44. WorldModelBench: <https://arxiv.org/abs/2502.20694>
- 45. RoboWM-Bench: <https://arxiv.org/abs/2604.19092>
- 46. MiraBench: <https://arxiv.org/abs/2605.29360>
- 47. 1X/WPE, Evaluating Robot Policies in a World Model: <https://arxiv.org/abs/2506.00613>

6.5 方法论说明

本报告采用横纵分析法：纵轴追踪概念从认知假说、model-based reinforcement learning、潜空间想象到视频基础模型与 World-Action Model 的演变；横轴以 2026 年 8 月为截面，对开放研究、基础设施平台、闭源真机策略和空间生成模型进行同口径比较。综合判断优先依据原始论文、官方技术报告、模型/代码仓库与明确披露的真机数据；无法独立核实的厂商主张不作为确定事实外推。